



EXP2-1 相同还是不同?

B 学期第 1-3 周


EXP2-1 的**目的**是开发工具和技能，：

- 以正确的方式（单位、有效数字、误差）呈现
和报告数据
- 确定数据是否具有统计意义

第 1 部分 随机变化

当我们重复测量一个数值时，每次得到的结果并不完全相同

通常，我们会看到某个值的随机变化



重复测量以揭示随机变化



一些定义

变量可以是

离散或分类：只有特定的值

例如：女性或男性的腿数

高分子学生或材料学生

连续或数值：可以是任何数值

例如，我们测量的大多数东西：长度、温度、质量、强度、刚度等。




一些定义

数据： 单个测量值（观测值）（如学生的 x 身高） **样本：** 若干相似的测量值（如 QMES

学生的身高） **群体：** 所有结果的假设集合（如中国学生的身高）


随机变化的群体遵循 "**正态分布**".

正态分布




表示某一数值与平均值相差一定距离的概率

中心倾向和分散



相同离散度不同平均值



平均值相同，离散度不同

中心倾向测量法



- 平均值
- 模式
- 中位数

中心倾向测量法



平均值

- 对民众而言

$$\mu = \frac{\sum X_i}{N}$$

- 样本方面

$$\bar{X} = \frac{\sum X_i}{n}$$

模式

- 一组数字中最常出现的数值
- 通常用于数据按类分组的情况--对类间隔敏感。
- 可以是 1 个值（单峰）或大于 1 个值（如双

峰、三峰)。

中位数

- 由数据集沿 $(n+1)/2$ 的位置定义 示例 1: 1 5 6

8 9

例 2: 200 200 230 250 280 300 350 400 480

例 3: 200 200 230 250 280 300 350 400 480 500

中位数 = $(280 + 300) / 2 = 290$

地点特征

中心倾向：

样本

人口

平均值或平均值

$$\bar{X} = \frac{\sum X}{n}$$

μ

n = 事件数（或测量数）

确定传播特性

分散:

样本

人口

范围

$X_{\text{（最大值）}} - X_{\text{（最小值）}} + \square \text{ 至 } \square$

标准差, (SD 或 St
Dev)

$$S = \sqrt{\frac{\sum (X - \bar{X})^2}{n - 1}} \quad \sigma = \sqrt{\frac{\sum (X - \bar{X})^2}{N}}$$

确定变异的特征



标准差，SD

内

1 SD= 68.26% 的人口


2 SD= 95.46% 人口

3 SD= 99.73% 的人口

...

6 个标清

□ 1/1 百万人口




表示某一数值与平均值相差一定距离的概率。

置信区间, CI

$x\%$ 的数值出现在平均值的某个范围内的概率

即我们有多大把握在这个范围内找到一个值?



例如

95% 置信区间 = $\square$ 平均值的 1.96 SD 99% 置信区间

= □ 平均值的 2.58 SD


变异系数, CV

$$C.V. = \frac{St\ Dev}{Mean}$$

测量宽度

或分布的锐度。

例如, $CV(A) < CV(B)$



Usually expressed as a percentage $CV\% = \frac{S}{\bar{X}} * 100$

在科学中，数据没有单一的价值、
我们还需要说明*我们对值的了解程度*

位置 $\square$ 分布 (n= 测量次数)


平均值 $\square$ St Dev, n

平均值 $\square$ x% 置信区间, n 平均值 + CV, n

使用其中 1 个

一定要说明你引用的是什么。


其他分发形式



Bimodal




Unimodal




Small Variability



Large Variability



Positively Skewed



Negatively Skewed

其他分发形式




中心倾向:

平均数 = 平均值 中位数= 中

间值

模式= 出现频率最高的数值



分散:

直方图 - 将数据分为不同类别或 "箱" 确定箱的数量:

使用 垃圾箱 $\sqrt{n}$ 或
 $3.3 \log n$ bins

斯特吉斯规则 $1 +$

(其中 n = 数据集中的观测总数)



- **人口** - 整个群体
- **样本** - 特定群体
- 概率样本并不能保证 "**正确**" 的答案是对基本**群体**值的估计
- **每个样本都有差异**，因此每个样本的估计值会不同（希望差别不大）。
- 不过，一个样本只是众多**可能的样本**之一



问题

- 如果我们只抽取一个样本，能否用这个样本来估计真实的总体值（未知数）？
- 估算有多精确？
- 为什么它很重要？

- 问题如果我们只抽取一个样本，能否用这个样本来估计真实的总体值（未知数）？可以--如果我们有**随机样本**的话！


- 为什么这很重要？

因为我们可以从**样本中归纳出**

人口！

而且--如果我们的抽样工作做得好--我们只需要抽取相对**较少**的**病例**，就能为**更大的人群**计算出相当精确的估计值。

样本平均值



样本1, 2, 3, ...

抽样手段: $\bar{X}_1, \bar{X}_2, \bar{X}_3 \dots$


- **样本均值**是随机变化
- 样本均值以总体均值为中心，只要有足够多的样本，所有样本均值的平均值 = 真实的总体均值

平均值的标准误差



抽样分布是样本平均值的分布图。

平均值的标准误差= 抽样分布的标准偏差



平均值的标准误差 (SE)

变得很重要：

如果我们知道什么是 SE，我们就能
评估特定样本代表 "真实" 人口值的
可能性多大。

中央极限定理



如果我们的样本相对较大 ($n > 30$)、

则**中心极限定理**成立。

这就告诉我们，抽样分布（样本平均值）将是

- 正态分布

- 样本平均数等于总体 $\bar{X} = \mu$

- 抽样分布的标准偏差 $SE = \frac{\sigma}{\sqrt{n}}$

- 已知属性（例如，**95%** 的样本平均值将在总体平均值的 1.96 标准误差范围内）， $95\% \text{ C.I.} = \bar{X} \pm 1.96SE$

- 如果 $n > 30$ ，那么即使目标人口**不是**
正态分布！

平均值的标准误差



所以呢？

因此，我们可以用公式 $\frac{\sigma}{\sqrt{n}}$ 来近似计算**标准误差**

的抽样分布（SE= 样本平均值的抽样分布标准偏差）

如果我们知道 SE，就能评估特定**样本代表 "真实"**
"人口值的可能性有多大。

平均值的标准误差



样本估计值的标准误差 (SE):

我们可以利用**中心极限定理**来估计平均值样本估计值的**准确性**

$$\text{SE (抽样分布的标准偏差)} \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

SE 表示**样本**平均值可能围绕着

人口平均数

- 是衡量抽样误差的一个指标，表明我们的抽样估计值接近**真实基本人口值的可能性**多大。

当 $n > 30$ 时，我们可以用上面的公式来估算。

平均值的标准误差



抽样分布的标准误差：

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

$$SD \text{ of population } \sigma = \sqrt{\frac{\sum (X - \bar{X})^2}{N}}$$

$$\sigma_{\bar{X}} = \frac{S}{\sqrt{n}}$$

$$SD \text{ of sample } S = \sqrt{\frac{\sum (X - \bar{X})^2}{n - 1}}$$

影响：

- 样本量 (n) 越大，样本误差就可能越小。
- 样本的标准差 (s) 越大，样本的误差就可能越大。

SE 和置信区间



通过估计值的标准误差，我们可以计算出
样本估计值的**置信区间**。

置信区间= 我们有理由确定**真实人口值**的范围。

置信区间是什么意思？

对于 95% 的置信区间，假设你收集了 100 个样本，那么真正的总体平均值将位于其中 95 个样本的置信区间内。

抽样分布的 SE 和 C.I.

当 $n > 30$ 时，CLT 成立，样本均值的置信区间也成立：


$$\text{Confidence interval} = \bar{X} \pm Z \cdot \sigma_{\bar{X}}$$

平均数的样本估计值

标准误差（样本标准偏差/
 n 的平方根）

z 是取自正态曲线的 z 值。
 z 值取决于我们愿意接受的误差程度。

置信区间



置信区间	90%	95%	99%
z	1.65	1.96	2.58



- **随机变化**遵循**正态分布**。
- **St Dev** 表示平均值的离散程度。
- **SE**（平均值的标准误差）表示一个样本平均值与 "真实"值（总体平均值）的差异。
- **置信区间**表示任何值的概率
与平均值相差一定距离。
- **变异系数**表示分布的宽度。
- **直方图**有助于显示分布的数值。

任务



- 在 QM+ 上检查小组作业
- 查看 "导言 "并遵循 "说明
- 从 QM+ 下载原始数据文件
- 按照 7 步计划，利用 GMM 解决问题
- 将您的问题带到课堂上讨论

EXP2-1 附表 - P 组



日期	时间	地点	活动：
星期一 17 th	08:30-10:10	QMES A310	QXU5017 简介 EXP2-1 第 1 部分
19 日星期三	08:30-10:10		小组会议 1（审查和检查原始数据）
星期五 21 st	10:30-12:10		小组会议 2（撰写报告第 1-4 部分）
24 日星期一	08:30-10:10	QMES A310	EXP2-1 简介第 2 部分
26 日星期三	08:30-10:10		小组会议 3（不同样本对比）
28 日星期五	10:30-12:10		第 4 组会议（完成报告第 5-8 节）
星期三 5 th	08:30-10:10	A310	提交报告

EXP2-1 计划表 - M 组



日期	时间	地点	活动：
星期一 17 th	10:30-12:10	QMES A310	QXU5017 简介 EXP2-1 第 1 部分
19 日星期三	10:30-12:10		小组会议 1（审查和检查原始数据）
星期五 21 st	08:30-10:10		小组会议 2（撰写报告第 1-4 部分）
24 日星期一	10:30-12:10	QMES A310	EXP2-1 简介第 2 部分
26 日星期三	10:30-12:10		小组会议 3（不同样本对比）
28 日星期五	08:30-10:10		第 4 组会议（完成报告第 5-8 节）
星期三 5 th	10:30-12:10	A310	提交报告

